
Statistics II


for Machine Learning Chap. 1: ML위한 선형대수


선형대수?


Linear algebra is the branch of mathematics concerning

- linear equations such as $a_1x_1 + ... + a_nx_n = b$
- linear functions such as $(x_1, ..., x_n) \mapsto a_1x_1 + ... + a_nx_n$










• and their representations in vector spaces and through matrices.

Vector

A **Euclidean vecto**r is represented by a line segment connecting an *initial point* O with a *terminal point* A.

A Euclidean vector (simply a vector) is a geometric object that has magnitude (or length) and direction




벡터는 크기(점수)와 방향(국어, 영어)의 값을 갖는 데이터를 순서대로 나열한 것데이터를 벡터로 표현하면, 벡터를 이용하여 처리할 수 있다

국어 점수=
$$\begin{bmatrix} 100 \\ 70 \\ 30 \\ 45 \\ 80 \end{bmatrix}$$
 영어 점수=
$$\begin{bmatrix} 100 \\ 70 \\ 30 \\ 45 \\ 80 \end{bmatrix}$$

Vector Space

A **vector space** (also called a **linear space**) is a **collection of objects** called vectors, which may be **added** together and **multiplied** ("scaled") by numbers, called **scalars**.

Vector spaces are well characterized by their <u>dimension</u>, which specifies the number of <u>independent</u> directions in the space.




벡터공간(vector space) 은 벡터의 선형결합으로 표현되며, 함수를 포함하여 모든 것을 벡터의 선형결합으로 표현할 수 있다

Linear Combination

다음의 C1, C2 는 모든 실수에 대응될 수 있으며, C1, C2 값이 바뀌면서 얻게 되는 선형결합의 결과는 2차원 실수 벡터공간의 모든 벡터에 대응된다.

이때의 두 벡터 [1,0], [0,1]는 기저벡터이어야 가능

$$C_1\begin{bmatrix}1\\0\end{bmatrix}+C_2\begin{bmatrix}0\\1\end{bmatrix}$$



Matrix


A **matrix** (plural **matrices**) is a rectangular array of numbers, symbols or expressions, arranged in rows and columns.

$$A = \begin{bmatrix} 1 & 2 & \dots & n \\ 1 & a_{11} & a_{12} & \dots & a_{1n} \\ 2 & a_{21} & a_{22} & \dots & a_{2n} \\ a_{31} & a_{32} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ m & a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} = \in \mathbb{R}^{m \times n} , \qquad AX = \lambda X$$

행렬은 벡터를 또 다른 벡터로 변환 시키는 일종의 연산자로 볼 수 있다

A <u>major application</u> of matrices is to represent <u>linear transformations</u>, that is, generalizations of linear functions.

행렬과 행렬의 곱 혹은 행렬과 벡터의 곱은 왼쪽 행렬의 행 요소들과 오른쪽 행렬의 열 요소들의 값들을 순서대로 곱해주고 더해주는 방법이다.



행렬 곱은 행 벡터와 열 벡터 간의 내적(inner product)을 계산함으로써 이루어진다.

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} = \begin{bmatrix} 1 \cdot a + 2 \cdot c & 1 \cdot b + 2 \cdot d \\ 3 \cdot a + 4 \cdot c & 3 \cdot b + 4 \cdot d \end{bmatrix}$$

▶ 열벡터의 선형결합

행렬의 곱을 다음의 수식표현에서처럼 열 벡터의 선형결합으로 이해할 수 있다.

벡터의 선형결합이 의미하는 것은 벡터 공간(vector space)의 생성을 의미


$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} a \\ c \end{bmatrix} = \begin{bmatrix} 1 \cdot a + 2 \cdot c \\ 3 \cdot a + 4 \cdot c \end{bmatrix} \qquad \Longrightarrow \qquad \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} a \\ c \end{bmatrix} = a \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} + c \cdot \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

> 우리가 익숙한 다음의 선형 연립방정식으로 행렬의 곱에 대해 살펴보자

$$\begin{cases} x + 2y = 3 \\ 3x + 4y = 5 \end{cases} \longrightarrow \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix} \longrightarrow x \begin{bmatrix} 1 \\ 3 \end{bmatrix} + y \begin{bmatrix} 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$$

》 위의 열 벡터 선형결합 수식을 해석적 관점에서 다시 표현한다면, 두 벡터 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 과 $\begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 의 선형결합으로 생성된 (x,y) 벡터공간 내에 $\begin{bmatrix} 3 \\ 5 \end{bmatrix}$ 가 존재하는가? 존재한다면, 두 벡터 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 과 $\begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 을 어떻게 조합하여야 하는가? 의 문제로 이해할 수 있다.

두 벡터 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 과 $\begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 의 선형결합으로 생성된 (x, y) 벡터공간 내에 $\begin{bmatrix} 3 \\ 5 \end{bmatrix}$ 가 존재하는가? 존재한다면, 두 벡터 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 과 $\begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 을 어떻게 조합하여야 하는가? 의 문제로 이해할 수 있다.





▶ 기저 벡터 변형을 통한 벡터의 선형변환

행렬의 곱 또는 행렬과 벡터의 곱을 기저 벡터의 변형을 통한 벡터의 선형 변환으로 해석


 \triangleright ex) 다음의 행렬A를 이용하여 기저 벡터 \vec{x} 를 변형

$$A = egin{bmatrix} 2 & -3 \ 1 & 1 \end{bmatrix} \qquad \vec{x} = egin{bmatrix} 1 \ 1 \end{bmatrix} \qquad egin{bmatrix} A ec{x} = egin{bmatrix} 2 & -3 \ 1 & 1 \end{bmatrix} egin{bmatrix} 1 \ 1 \end{bmatrix} egin{bmatrix} 1 \ 1 \end{bmatrix} = egin{bmatrix} -1 \ 2 \end{bmatrix}$$





Matrix



Matrix



변수 관측치	X,	 X,	 X _p
N ₁	x ₁₁	 x _{Ii}	 x _{Ip}
N ₂	x ₂₁	 x _{2i}	 x _{2p}
N _{n-1}	X _{n-11}	 X _{n-li}	 X _{n-ip}
N _n	X _{nj}	 X _{ni}	 X _{np}

20.5


22.2

72.3

82.8

Linear Combination







$$D_{1} \begin{bmatrix} \alpha_{1} \\ \alpha_{2} \\ \vdots \\ \alpha_{l} \end{bmatrix} + D_{2} \begin{bmatrix} \beta_{1} \\ \beta_{2} \\ \vdots \\ \beta_{l} \end{bmatrix} + \dots + D_{m} \begin{bmatrix} \theta_{1} \\ \theta k_{2} \\ \vdots \\ \theta_{l} \end{bmatrix}$$


Linear Combination



$$C_1 \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix} + C_2 \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} + \dots + C_k \begin{bmatrix} k_1 \\ k_2 \\ \vdots \\ k_n \end{bmatrix}$$



$$D_{1}\begin{bmatrix} \alpha_{1} \\ \alpha_{2} \\ \vdots \\ \alpha_{l} \end{bmatrix} + D_{2}\begin{bmatrix} \beta_{1} \\ \beta_{2} \\ \vdots \\ \beta_{l} \end{bmatrix} + \dots + D_{m}\begin{bmatrix} \theta_{1} \\ \theta k_{2} \\ \vdots \\ \theta_{l} \end{bmatrix}$$




Linear Transformation

For example, the 2×2 matrix, $A = \begin{bmatrix} a & c \\ b & d \end{bmatrix}$ Eigen Vectors, Eigen Values

can be viewed as the transform of the <u>unit square</u> into a parallelogram with vertices

at (0, 0), (a, b), (a + c, b + d), and (c, d).



determinant of a matrix A : det(A)

행렬식(determinant)은 해당 벡터로 만들어지는 영역으로서, 해당 벡터의 행렬식 값이 0 → 해당 벡터는

해당 벡터의 행렬식 값이 0 → 해당 벡터는 동일한 선상에 존재하는 벡터를 의미


The parallelogram is obtained by multiplying A with each of the column vectors.

 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ and $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$. These vectors define the vertices of the <u>unit square</u>.

Linear Transformation

For example, when we apply linear transformation A to a circle


$$A = \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix}$$



- The dot product of the Cartesian coordinates of two vectors is often called the inner product (or rarely projection product)
- 유사도(similarity) 측정에 사용

Algebraic definition

Two vectors (or matrices) **A** and **B**, A is $m \times n$ and B is $n \times p$, then the dot product $A \cdot B$ is $m \times p$ matrix



Geometric definition

Geometrically, the dot product of the two vectors is the **cosine** of the angle between them.

$$a \cdot b = ||a|| ||b|| \cos\theta$$

√ <u>correlation</u>

The illustration pictured at right show <u>how to find the angle</u> between vectors using the dot product




$$a \cdot b = 0$$
, $\because cos 90^{\circ} = 0$

✓ If the vectors **a** and **b** are **codirectional** (the angle between them is 0°)


$$a \cdot b = ||a|| ||b||$$
, $\therefore cos0^\circ = 1$

✓ The dot product of a vector **a** with itself is

$$a \cdot a = ||a||^2$$
, $||a|| = \sqrt{a \cdot a}$. That is **Euclidean length** of the vector a .



Data & matrix



$$X = \left(egin{array}{c} x_1 \ x_2 \ \dots \ x_n \end{array}
ight)$$


$$X = \begin{pmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{pmatrix} \qquad X = (x_1, x_2, \dots, x_n)^T$$

$$L_x = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} = \sqrt{X^T X}$$

Length & Cosine angle


$$X = (x_1, x_2, ..., x_n)^T$$
, $Y = (y_1, y_2, ..., y_n)^T$
 $< X, Y > = X \cdot Y = X^T Y = \sum_{i=1}^n x_i y_i = x_1 y_1 + x_2 y_2 + ... + x_n y_n$

$$cos\theta = \frac{X \cdot Y}{\|X\| \|Y\|} = \frac{X^T Y}{L_x L_y} = \frac{X^T Y}{\sqrt{X^T X} \sqrt{Y^T Y}}$$



선형변환 & 고유벡터

• 행렬 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 의 선형변환



선형변환 & 고유벡터

An <u>eigenvector</u> (or characteristic vector) of a <u>linear transformation</u> is a nonzero vector that changes at most by a <u>scalar factor</u> when that linear transformation is applied to it.

$$AX = \lambda X$$

• A: matrix of the data, ie linear transformation


• X: eigen vector for the linear transformation

• λ : eigen value for the linear transformation


즉, 행렬 A 의 선형변환을 <u>eigenvector</u> 와 <u>eigenvalue</u> 성분으로 **분해**한다는 것이다.

특성	기저 벡터	고유벡터
정의	선형공간의 모든 벡터를 선형결합으로 나타낼 수 있는 벡터들의 집합	선형결합에 의해 방향이 변하지 않는 벡터
방향	변하지 않음	변함
크기	변하지 않음	변함(고유값이 변화의 크기임)
선형 독립성	선형독립일 필요 없음	선형독립이어야 함
사용목적	선형공간의 구조를 이해하는데 사용	선형변환(행렬)을 이해하는데 사용

기저 벡터: ā b̄



• 고유 벡터



선형변환 & 고유벡터

Eigen Vector & Eigen Value

The meaning of eigenvectors and eigenvalues for <u>linear transformation</u> matrix **A**


- ✓ Eigen vector: *direction* of the *linear transformation*
- ✓ Eigen value: *magnitude* of the *linear transformation*

For example,

$$\lambda_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad \lambda_1 = 1, \quad \lambda_2 = 3$$


$$\lambda_1 = 1, \quad V_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$


$$\lambda_2 = 3, \quad V_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$





❖ 고유벡터들은,
$$V = [V_1 \ V_2] = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$$
, 서로 직교한다. 방향은 그대로, 크기만 변화.


선형변환 & 고유벡터











공분산(Covariance)

ID	국어	영어
1	95	95
2	90	95
3	80	75
4	60	70
5	40	35
6	80	80
7	95	90
8	30	25
9	15	10
10	60	70
평균	64.5	64.5
분산	808	925
공분산	76	52



ID	국어	영어
	9.5	9.5
2	9.0	9.5
3	8.0	7.5
4	6.0	7.0
5	4.0	3.5
6	8.0	8.0
	9.5	9.0
8	3.0	2.5
9	1.5	1.0
10	6.0	7.0
평균	6.45	6.45
분산	8.08	9.25
공분산	7.	62

$$\checkmark Cov(x,y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

✓ 공분산: X의 편차와 Y의 편차를 곱한 값들의 평균으로, 데이터에 따라 공분산 크기가 달라진다.

• $Cov(X,Y) > 0 : X\uparrow$, $Y\uparrow$


• $Cov(X,Y) < 0 : X \uparrow , Y \downarrow$

Cov(X,Y) = 0 : No linear relationship


✓ 공분산은 두 변수 간에 양의 상관관계가 있는지? 음의 상관관계가 있는지? 정도만 알려줌

✓ 상관관계가 얼마나 큰지는 제대로 반영하지 못함


분산 & 공분산




$$Var(x) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2$$



$$Cov(x,y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$



$$Cov(x, y) = +$$



$$Cov(x, y) = -$$

상관계수(Correlation Coefficient)

ID	국어	영어
1	95	95
2	90	95
3	80	75
4	60	70
5	40	35
6	80	80
7	95	90
8	30	25
9	15	10
10	60	70
평균	64.5	64.5
분산	808	925
공분산	70	62



ID	국어	영어
1	9.5	9.5
2	9.0	9.5
3	8.0	7.5
4	6.0	7.0
5	4.0	3.5
6	8.0	8.0
7	9.5	9.0
8	3.0	2.5
9	1.5	1.0
10	6.0	7.0
평균	6.45	6.45
분산	8.08	9.25
공분산	7.62	


$$\gamma = \frac{Cov(x, y)}{\sqrt{Var(x)}\sqrt{Var(y)}} = \frac{762}{\sqrt{808}\sqrt{925}} = 0.88$$

$$\gamma = \frac{Cov(x,y)}{\sqrt{Var(x)}\sqrt{Var(y)}} = \frac{7.62}{\sqrt{8.08}\sqrt{9.25}} = 0.88$$

상관계수(Correlation Coefficient)

- 상관계수: **공분산을 표준화한 값**
- 절대값은 1보다 작거나 같음
- X, Y가 완벽한 선형관계이면, γ =1 or -1
- 상관계수가 1 또는 -1에 근접할수록 힘(power)가 크다는 것
- 여기서의 힘이란 점들이 모여있는 정도

상관계수(Correlation Coefficient)



내적 & 상관계수

$$Cov(X,Y) = E(X - \mu_X)(Y - \mu_Y) = E[XY] - \mu_X \mu_Y$$

$$= \frac{1}{N} \sum_{i=1}^{N} X_i Y_i - \mu_X \mu_Y$$

$$= \frac{1}{N} \langle X, Y \rangle - \mu_X \mu_Y$$

$$\rho = \frac{1}{N} \sum_{i=1}^{N} \left(\frac{X_i - \mu_X}{\sigma_X} \right) \left(\frac{Y_i - \mu_Y}{\sigma_Y} \right)$$

$$if \ \mu_X \& \mu_Y = 0$$

$$1 \sum_{i=1}^{N} X_i Y_i \qquad \langle X, Y \rangle \qquad \langle X, Y \rangle$$

$$= \frac{1}{N} \sum_{i=1}^{N} \frac{X_i Y_i}{\sigma_X \sigma_Y} = \frac{\langle X, Y \rangle}{\sqrt{\sum X^2} \sqrt{\sum Y^2}} = \frac{\langle X, Y \rangle}{\|X\| \|Y\|}$$
$$= \cos \theta$$

- ✓ 내적 $a \cdot b$ ($a^T b$, $\langle a, b \rangle$) 결과 행렬로부터 공분산을 구하기 위해서는 원래의 data matrix에서 평균이 zero가 되도록 **표준화** 해주어야 한다.
- ✓ 상관계수 ρ 는 두 벡터 간의 $cos\theta$ 값이 되기 때문에 $-1 \le \rho \le 1$ 갖게 된다.
- \checkmark 표준화 한 경우에는, 상관계수 ρ = 내적의 $\cos\theta$ 성립하며,

$$Cov(X,Y) = \langle X,Y \rangle$$